

Пармеев Денис Владимирович

AI/LLM Systems Engineer

□ Пенза (готов к переезду: Москва, СПб, Нижний Новгород, Сочи; удалённо) □ +7 (999) 110-03-09

□ topitip@icloud.com

ПРОФИЛЬ

AI/LLM инженер с 7+ годами в разработке и 2+ годами проектирования production-grade LLM систем. Специализация: агентные архитектуры на LangChain/LangGraph, RAG-пайплайны, ASR/синхронный перевод (Whisper), on-premise LLM-инфраструктура под требования **152-ФЗ**, тарификация и мониторинг токенов через LiteLLM. Реализую полный цикл — от архитектуры до деплоя и интеграции в рабочие процессы команд.

ОПЫТ РАБОТЫ — 7 ЛЕТ

Gravity Group

апр. 2025 — н.в. · 10 мес.

AI/LLM Systems Engineer

- Спроектировал корпоративную **LLM-инфраструктуру on-premise**: изолированные агенты под каждого заказчика, тарификация и бюджетирование токенов, соответствие 152-ФЗ и NDA.
- Развернул **LiteLLM proxy** с выдачей индивидуальных API-ключей разработчикам, мониторингом usage по моделям и командам; договорился со Сбером о скидках на корпоративные LLM-модели.
- Разработал **AI-агента** для корпоративных Telegram-чатов и GitLab: авто-сбор задач из чатов и task-трекеров, генерация документации (DOCX/Excel), браузерное тестирование, написание автотестов.
- Спроектировал **SyncVoice** — систему синхронного перевода речи (RU/EN/HI/ZH) для фармацевтического enterprise: on-premise Whisper ASR + пайплайн перевода в реальном времени, без облаков.
- Построил **RAG-пайплайн** на Qdrant + OpenSearch: индексация корпоративных документов, семантический поиск, контекстное обогащение запросов к LLM.

Стек: Python, FastAPI, LangChain, LangGraph, LiteLLM, OpenClaw, Whisper AI, Qdrant, OpenSearch, RAG, n8n, LangFlow, RabbitMQ, Redis, PostgreSQL, Docker

Lumines Fox

апр. 2021 — мар. 2024 · 3 года

Founder / Lead ML Engineer

- Корпоративная платформа знаний с **ML-пайплайном транскрипции**: 6 воркеров на FastAPI + RabbitMQ, ASR точность **95–97%**, диаризация спикеров **>90%**. Ускорение в **36–65 раз** — с 13+ мин до 12–22 сек на часовое видео.
- Использовал **PyTorch + Whisper** для fine-tuning и оптимизации инференса; оптимизировал батчинг и параллелизм воркеров под ограничения on-premise GPU.
- Реализовал **векторный поиск** по транскрипциям через Qdrant; RAG-ответы на вопросы по корпусу встреч и документов.
- Полная офлайн-работа (152-ФЗ): OAuth2 Authorization Server (RFC 6749), PKCE, JWT blacklist в Redis.

Стек: Python, PyTorch, Whisper, FastAPI, RabbitMQ, Qdrant, OpenSearch, Minio, Redis, PostgreSQL, Docker

Fullstack Developer

- Банковская CRM (React/C#), 2D-движок для редактора одежды (GSAP/Anime.js), Vue.js SPA и NativeScript mobile.
- Сильная фундаментальная база в fullstack-разработке — основа для построения сложных AI-систем.

КЛЮЧЕВЫЕ НАВЫКИ

AI / LLM / ML

LangChain

LangGraph

LiteLLM

OpenClaw

Whisper AI

PyTorch

RAG

Agents

n8n

LangFlow

Qdrant

OpenSearch

Frontend (доп.)

SvelteKit

Vue 3

React

TypeScript

Backend / Инфраструктура

Python

FastAPI

RabbitMQ

Redis

PostgreSQL

Docker

Linux

Nginx

GitLab CI

152-ФЗ

OAuth2/JWT

gRPC

Экспертиза

On-premise LLM

Token billing

ASR pipeline

Vector search

Multi-agent

ML inference opt.

ДОПОЛНИТЕЛЬНО

Образование

КТ ПензГТУ, Компьютерные сети,
2021

Языки

Русский (родной) · Английский B2

Формат работы

Удалённо · Офис · Гибрид