

SyncVoice™ — Аппаратное обеспечение

SyncVoice™ — Варианты аппаратного обеспечения

Платформа синхронного речевого перевода Дата: 23 февраля 2026

Обзор

Система поддерживает четыре конфигурации on-premise развёртывания. Клиент выбирает исходя из бюджета, доступности оборудования и требований к числу участников конференции.

Сравнение конфигураций

Параметр	NVIDIA A100/A10	NVIDIA RTX 4090/5090	Apple Mac Studio	NVIDIA DGX Spark
GPU	A10/A100 (CUDA)	RTX 4090/5090 (CUDA)	M2/M3/M4 Ultra (MPS)	GB10 Blackwell (CUDA)
Память	64–128 GB + VRAM	32–128 GB + VRAM	96–192 GB unified	128 GB unified
Форм-фактор	Tower / Rack	Tower / Rack	Компактный	Компактный
Цена (РФ)	1.5M – 5M □	500K – 2.2M □	400K – 900K □	~400K □
Max (≤2s SLA)	8–15	6–12	5–8	10–15
Max (≤3s SLA)	15–25	10–20	8–12	15–20
Доступность в РФ	Серый рынок	Доступны	Доступны	Серый рынок
Сложность настройки	Средняя	Низкая	Высокая	Низкая

Конфигурация 1: NVIDIA-сервер — A10 / A100

Датацентровые GPU NVIDIA (A10, A100) находятся под экспортными ограничениями и доступны в РФ только через серый рынок. Цены ориентировочные и могут существенно варьироваться.

Для крупных инсталляций с максимальным числом участников и несколькими языками.

Параметр	Минимум	Рекомендуемое
GPU	1× NVIDIA A10 (24 GB)	2× NVIDIA A100 (40/80 GB)
CPU	8 ядер (x86_64)	16+ ядер
RAM	32 GB	64 GB
SSD	256 GB	1 TB
Сеть	1 Gbps	10 Gbps
OS	Ubuntu 22.04 LTS	Ubuntu 22.04 LTS

Конфигурация GPU	Max (≤2s)	Max (≤3s)	Цена сервера (РФ)
1× A10 (24 GB)	5–6	8–10	1 000 000 – 2 000 000 ☐
1× A100 (40 GB)	8–12	15–18	1 500 000 – 3 000 000 ☐
2× A100 (40 GB)	15–20	25–30	3 000 000 – 5 000 000 ☐
2× A100 (80 GB)	20–25	30–40	4 000 000 – 6 000 000 ☐

Конфигурация 2: NVIDIA-сервер — RTX 4090 / 5090 ☐ Рекомендуется

Оптимальное соотношение цены и производительности для большинства инсталляций в РФ.
Consumer/prosumer GPU без жёстких экспортных ограничений.

Параметр	RTX 4090	RTX 5090
VRAM	24 GB GDDR6X	32 GB GDDR7
Архитектура	Ada Lovelace	Blackwell
FP16	~82 TFLOPS	~220 TFLOPS
RTF (SeamlessM4T)	~0.7–1.0	~0.4–0.6
Цена карты (РФ)	300 000 – 400 000 ☐	500 000 – 700 000 ☐
Цена сервера (РФ)	500 000 – 700 000 ☐	800 000 – 1 200 000 ☐

Конфигурация	Max (≤2s)	Max (≤3s)	Цена сервера (РФ)	Примечание
1× RTX 4090 (24 GB)	6	10	500 000 – 700 000 ☐	☐ Протестировано
2× RTX 4090 (24 GB)	~12	~18	900 000 – 1 300 000 ☐	Параллелизм по GPU
1× RTX 5090 (32 GB)	~10	~15	800 000 – 1 200 000 ☐	~1.5× быстрее 4090

Конфигурация	Max (≤2s)	Max (≤3s)	Цена сервера (РФ)	Примечание
2× RTX 5090 (32 GB)	~18	~25	1 500 000 – 2 200 000 ₽	Наилучший баланс

Конфигурация 3: Apple Mac Studio ☐ Рекомендуется для РФ

Компактное решение с хорошей доступностью в России. Уникальная unified memory архитектура — модели загружаются полностью без ограничений VRAM.

Параметр	Значение
Чип	Apple M2 Ultra / M3 Ultra / M4 Ultra
Память	96–192 GB unified memory
OS	macOS 14 Sonoma и выше
Деплой	Гибридный: сервисы в Docker Desktop, ML-агент нативно через PyTorch MPS

Конфигурация	Max (≤2s)	Max (≤3s)	Цена (РФ)
M2 Ultra (192 GB)	~5	~8	400 000 – 600 000 ₽
M3/M4 Ultra (192 GB)	~7	~10	600 000 – 900 000 ₽

Конфигурация 4: NVIDIA DGX Spark

Компактный AI-кирпич на базе Blackwell. Стандартный CUDA-стек — простой деплой, высокая производительность при минимальном размере.

Параметр	Значение
Чип	NVIDIA GB10 Grace Blackwell Superchip
Память	128 GB unified (CPU + GPU, NVLink-C2C)
Производительность	1 PFLOP FP4
OS	Ubuntu (DGX OS)
Деплой	Full Docker + NVIDIA Container Toolkit
Форм-фактор	Компактный (размер Mac mini)
Цена (РФ)	~400 000 ₽ (серый рынок)

Конфигурация	Max (≤2s)	Max (≤3s)
1× DGX Spark	~10	~15
2× DGX Spark (NVLink)	~18	~25

Рекомендации по выбору

Сценарий	Рекомендация
Бюджет до 500K $\square$, до 6 участников (≤2s)	RTX 4090
Бюджет до 700K $\square$, до 8 участников (≤3s)	RTX 4090 или Mac Studio M2 Ultra
Бюджет до 1M $\square$, до 10 участников (≤2s)	RTX 5090 или Mac Studio M3/M4 Ultra
Компактность + простота, до 10 участников	DGX Spark
Максимум участников (15+)	2× RTX 5090 или 2× A100

Цифры для RTX 4090 подтверждены нагрузочным тестированием. Остальные конфигурации — экстраполяция на основе относительной производительности GPU.

Цены ориентировочные, актуальны на февраль 2026. Цены на NVIDIA датацентровые GPU (A10, A100) могут существенно варьироваться ввиду поставок через серый рынок.

SyncVoice™ — on-premise платформа синхронного речевого перевода