

SyncVoice™ — Аппаратное обеспечение

SyncVoice™ — Варианты аппаратного обеспечения

Платформа синхронного речевого перевода Дата: 23 февраля 2026

Обзор

Система поддерживает четыре конфигурации on-premise развёртывания. Клиент выбирает исходя из бюджета, доступности оборудования и требований к числу участников конференции.

Сравнение конфигураций

Параметр	NVIDIA A100/A10	NVIDIA RTX 4090/5090	Apple Mac Studio	NVIDIA DGX Spark
GPU	A10/A100 (CUDA)	RTX 4090/5090 (CUDA)	M2/M3/M4 Ultra (MPS)	GB10 Blackwell (CUDA)
Память	64–128 GB + VRAM	32–128 GB + VRAM	96–192 GB unified	128 GB unified
Форм-фактор	Tower / Rack	Tower / Rack	Компактный	Компактный
Цена (РФ)	1.5M – 5M □	500K – 2.2M □	400K – 900K □	~400K □
Мах участников	10–30	5–20	5–10	8–12
Доступность в РФ	Серый рынок	Доступны	Доступны	Серый рынок
Сложность настройки	Средняя	Низкая	Высокая	Низкая

Конфигурация 1: NVIDIA-сервер — A10 / A100

Датацентровые GPU NVIDIA (A10, A100) находятся под экспортными ограничениями и доступны в РФ только через серый рынок. Цены ориентировочные и могут существенно варьироваться.

Для крупных инсталляций с максимальным числом участников и несколькими языками.

Параметр	Минимум	Рекомендуемое
GPU	1× NVIDIA A10 (24 GB)	2× NVIDIA A100 (40/80 GB)

Параметр	Минимум	Рекомендуемое
CPU	8 ядер (x86_64)	16+ ядер
RAM	32 GB	64 GB
SSD	256 GB	1 TB
Сеть	1 Gbps	10 Gbps
OS	Ubuntu 22.04 LTS	Ubuntu 22.04 LTS

Конфигурация GPU	Мах участников	Цена сервера (РФ)	Примечание
1× A10 (24 GB)	5–6	1 000 000 – 2 000 000 ₺	2 языка, без запаса
1× A100 (40 GB)	8–10	1 500 000 – 3 000 000 ₺	3 языка, комфортно
2× A100 (40 GB)	15–20	3 000 000 – 5 000 000 ₺	3 языка, с запасом
2× A100 (80 GB)	20–30	4 000 000 – 6 000 000 ₺	4+ языка, batch inference

Конфигурация 2: NVIDIA-сервер — RTX 4090 / 5090 ☐ Рекомендуется

Оптимальное соотношение цены и производительности для большинства инсталляций в РФ.
Consumer/prosumer GPU без жёстких экспортных ограничений.

Параметр	RTX 4090	RTX 5090
VRAM	24 GB GDDR6X	32 GB GDDR7
Архитектура	Ada Lovelace	Blackwell
FP16	~82 TFLOPS	~220 TFLOPS
RTF (SeamlessM4T)	~0.7–1.0	~0.4–0.6
Цена карты (РФ)	300 000 – 400 000 ₺	500 000 – 700 000 ₺
Цена сервера (РФ)	500 000 – 700 000 ₺	800 000 – 1 200 000 ₺

Конфигурация	Мах участников	Цена сервера (РФ)	Примечание
1× RTX 4090 (24 GB)	5–8	500 000 – 700 000 ₺	3 языка, минимальный запас
2× RTX 4090 (24 GB)	10–15	900 000 – 1 300 000 ₺	3 языка, с запасом
1× RTX 5090 (32 GB)	8–12	800 000 – 1 200 000 ₺	3 языка, комфортно

Конфигурация	Мах участников	Цена сервера (РФ)	Примечание
2× RTX 5090 (32 GB)	15–20	1 500 000 – 2 200 000 ₽	4+ языка, batch inference

Конфигурация 3: Apple Mac Studio — Рекомендуется для РФ

Компактное решение с хорошей доступностью в России. Уникальная unified memory архитектура — модели загружаются полностью без ограничений VRAM.

Параметр	Значение
Чип	Apple M2 Ultra / M3 Ultra / M4 Ultra
Память	96–192 GB unified memory
OS	macOS 14 Sonoma и выше
Деплой	Гибридный: сервисы в Docker Desktop, ML-агент нативно через PyTorch MPS

Конфигурация	Мах участников	Цена (РФ)	Примечание
M2 Ultra (192 GB)	6–8	400 000 – 600 000 ₽	3 языка
M3/M4 Ultra (192 GB)	8–10	600 000 – 900 000 ₽	3 языка, комфортно

Конфигурация 4: NVIDIA DGX Spark

Компактный AI-кирпич на базе Blackwell. Стандартный CUDA-стек — простой деплой, высокая производительность при минимальном размере.

Параметр	Значение
Чип	NVIDIA GB10 Grace Blackwell Superchip
Память	128 GB unified (CPU + GPU, NVLink-C2C)
Производительность	1 PFLOP FP4
OS	Ubuntu (DGX OS)
Деплой	Full Docker + NVIDIA Container Toolkit
Форм-фактор	Компактный (размер Mac mini)
Цена (РФ)	~400 000 ₽ (серый рынок)

Конфигурация	Мах участников	Примечание
1× DGX Spark	8–12	3 языка, комфортно
2× DGX Spark (NVLink)	15–20	3–4 языка

Рекомендации по выбору

Сценарий	Рекомендация
Бюджет до 500K $\square$, до 8 участников	RTX 4090 или Mac Studio M2 Ultra
Бюджет до 1M $\square$, до 10 участников	RTX 5090 или Mac Studio M3/M4 Ultra
Компактность + простота + до 12 участников	DGX Spark
Максимальное число участников (15+)	2× RTX 5090 или 2× A100

Цены ориентировочные, актуальны на февраль 2026. Цены на NVIDIA датацентровые GPU (A10, A100) могут существенно варьироваться ввиду поставок через серый рынок.

SyncVoice™ — on-premise платформа синхронного речевого перевода